

大规模电商数据集 Polars 性能分析报告

Analysis of a Large Dataset Using Polars Open-Source Library

课程：IN6299 / IS6799 / KM6399 Critical Inquiry

小组编号：VH-03-02

指导教师：Vaidhyanathan Hariharan

成员：

姓名	学号	专业
Yu Ruotong	G2509000K	MSc Information Systems
Wang Siqi	G2507869C	MSc Information Studies
Fang Yuanjun	G2503411F	MSc Information Systems

报告日期：2026 年 4 月

目录

- 1. 项目背景与研究动机
- 2. 研究目标与整体框架
- 3. 数据集介绍
- 4. Task 1：数据预处理
- 5. Task 2：性能基准测试
- 6. Task 3：基线探索性数据分析（EDA）
- 7. Task 4：用户行为模式分析
- 8. Task 5：推荐导向分析
- 9. 综合性能对比与讨论
- 10. 结论
- 11. 参考文献

1. 项目背景与研究动机

随着电商平台的快速发展，平台每天产生海量的用户交互数据，包括商品浏览、加入购物车（Cart）和下单购买（Purchase）等行为记录。这些数据蕴含着丰富的用户偏好信号与商业价值，是优化推荐系统、制定营销策略、提升用户体验的核心资产。

然而，传统 Python 数据分析工具——以 Pandas 为代表——在面对千万级规模数据时暴露出明显的局限性：内存占用随数据量线性甚至指数级膨胀，在执行大规模分组聚合（GroupBy）、窗口函数（Window Functions）和多列排序时性能急剧下降，甚至因内存不足而崩溃。这使得数据团队在实际生产环境中不得不依赖昂贵的分布式计算平台，提高了技术门槛与运营成本。

Polars 是一个基于 Rust 构建的开源 DataFrame 库，专为高性能和大规模数据处理而设计。其核心优势包括：

- 惰性求值（Lazy Evaluation）**：将用户的查询语句构建为计算图（Query Plan），由优化器统一分析并自动执行谓词下推（Predicate Pushdown）、列裁剪（Projection Pushdown）等优化，减少不必要的数据读取。
- 多线程并行计算**：充分利用多核 CPU，在 Rust 底层实现高效并行聚合，避免 Python GIL 的制约。
- 流式处理（Streaming）引擎**：支持分块读取数据，使得在有限内存下处理超大规模数据集成为可能。

本项目选取 *RecSys 2020 Preprocessed eCommerce Behavior Dataset*（以下简称“数据集”）作为研究对象，通过系统性的实验设计，在同一业务分析任务上并行实现 Pandas 与 Polars 两套代码，量化对比两者在执行时间、内存消耗和可扩展性方面的差异，同时从数据中提取具有实际业务价值的电商洞察。

2. 研究目标与整体框架

2.1 研究目标


本项目的核心研究目标如 Proposal 所述，包含六个方面：

- 构建标准化的分析框架，为电商用户数据的系统性研究提供基础。
- 使用 Pandas 和 Polars 分别完成数据预处理，包括缺失值处理、过滤和子集划分。
- 执行基线探索性数据分析，为可视化和数据摘要提供支撑。
- 基于用户行为序列完成用户行为模式分析。
- 运用关联规则和频繁项集挖掘技术识别购物趋势，支持推荐与促销机制。

6. 通过处理速度与能力的对比，评估 Polars 在大规模数据分析中的优势。

2.2 整体分析框架

整个项目按照五个模块顺序推进，后一个模块建立在前一个模块的输出基础之上：



2.3 技术栈

工具	版本	用途
Python	3.11	主语言
Pandas	2.3.3	传统数据处理框架（对比基准）
Polars	1.37.1	高性能数据处理框架（主要分析引擎）
psutil	7.0.0	内存监控
Matplotlib / Seaborn	—	数据可视化

工具	版本	用途
Jupyter Notebook	—	交互式开发环境

3. 数据集介绍

3.1 基本信息

- 名称：RecSys 2020 Preprocessed eCommerce Behavior Data From Multi-Category Store Dataset
- 来源：Kaggle (Schettler, 2021)
- 文件格式：Parquet (列式存储，天然支持高效 I/O 和谓词下推)
- 数据规模：**11,495,242 行 × 19 列**
- 时间范围：2019 年 10 月 1 日至 2020 年 2 月 29 日 (约 5 个月)

3.2 字段说明

字段名	类型	描述
event_time	String	事件发生时间 (原始字符串)
event_type	String	事件类型: cart (加购) 或 purchase (购买)
product_id	String	商品唯一标识符
brand	String	品牌名称 (含缺失值)
price	String	商品价格 (原始为字符串, 含无效值, 需转换)
user_id	String	用户标识符
user_session	String	会话标识符 (用于划分用户单次访问)
target	Int64	目标标签
cat_0 ~ cat_3	String	多级商品品类 (顶级至细分)
timestamp	—	时间戳 (派生字段)
ts_hour / ts_weekday 等	—	时间衍生特征

3.3 数据特征

本数据集的事件类型仅包含 `cart` 和 `purchase` 两类（不包含 `view`），这意味着所有记录均代表用户有实质意图的交互行为，数据的业务信噪比较高，适合用于转化漏斗分析和关联规则挖掘。

4. Task 1：数据预处理

对应文件：`data_preprocessing_benchmark.ipynb`

4.1 数据质量问题

在对原始 `train.parquet` 进行质量审查后，发现以下主要问题：

- 1. **缺失值以字符串 "NA" 表示**：数据中的空值并非 Python 原生 `None / NaN`，而是字符串 `"NA"`，需要先替换为真正的空值再进行后续处理。
- 2. **price 字段为字符串类型**：原始价格以文本形式存储，无法直接参与数值运算，需转换为浮点数并过滤 ≤ 0 的无效记录。
- 3. **event_time 字段需标准化**：原始时间字符串格式不一致，需统一解析为 `Datetime` 类型，并提取派生时间特征（`event_date`、`event_hour`、`event_weekday` 等）供后续分析使用。
- 4. **品牌字段存在缺失**：在 10% 子集中，清洗后仍有约 94,294 条记录的 `brand` 字段为空（占比约 8.2%），这部分数据在品牌分析中将被过滤，但在其他分析中予以保留。

4.2 预处理流程

原始数据

- └ 替换字符串 `"NA"` → 真正的 `null`
- └ `price` 列: `str` → `float`，过滤 $\text{price} \leq 0$
- └ `event_time` → 解析为 `Datetime` (UTC)
- └ 提取衍生时间特征：
 - `event_date` / `event_hour` / `event_weekday` /
 - `event_day` / `event_month` / `event_year`

两个框架均以相同的逻辑实现上述流程，确保数据输出完全一致，为后续的公平性能对比打下基础。

4.3 数据子集生成

为支持不同规模下的性能测试，将清洗后的数据按比例生成三个子集：

子集	原始行数	清洗后行数	删除行数	删除比例
10%	1,149,524	1,148,774	750	0.065%
50%	5,747,621	5,743,817	3,804	0.066%
100%	11,495,242	11,487,615	7,627	0.066%

数据整体质量较高，删除比例约为 0.066%，绝大部分记录均通过质量检验。

子集文件保存于 `artifacts/clean_subsets/` 目录，后续所有分析任务均使用 `train_clean_100pct.parquet`（100% 清洗版）作为主数据源。

5. Task 2：性能基准测试

对应文件：`data_preprocessing_benchmark.ipynb`

5.1 测试设计

性能测试贯穿整个项目，在每一个分析操作上均同时运行 Pandas 和 Polars 两套实现，记录以下指标：

- **执行时间 (Execution Time)**：使用 `time.perf_counter()` 精确计时
- **峰值内存 (Peak Memory)**：通过独立守护线程每 0.1 秒采样 `psutil` 内存，记录峰值
- **内存增量 (Delta Memory)**：相较于任务启动前的内存增加量
- **内存安全熔断**：当进程内存超过设定阈值（12 GB）时，自动跳过 Pandas 全量任务，避免系统崩溃

本节重点报告 Task 1&2（预处理与聚合）阶段的基准结果。

5.2 数据加载性能 (load_raw_parquet)

子集规模	Pandas 耗时 (s)	Polars 耗时 (s)	Polars 加速比
10% (1.1M 行)	0.657	0.217	3.0×
50% (5.7M 行)	1.422	0.997	1.4×
100% (11.5M 行)	⚠ 内存熔断	1.734	—

注：Pandas 在 100% 全量数据加载时因估计内存需求（约 3.4 GB）超过安全阈值而被自动跳过；Polars 借助流式引擎顺利完成。

5.3 预处理流水线性能（preprocess_pipeline）

子集规模	Pandas 耗时 (s)	Polars 耗时 (s)	Polars 加速比
10%	6.898	0.222	31.0×
50%	33.199	1.963	16.9×
100%	⚠️ 内存熔断	3.282	—

预处理流水线是性能差距最悬殊的场景之一。Polars 在 10% 子集上即实现了约 **31 倍** 的加速，这主要来源于 Polars 的惰性求值优化器将多个字段转换操作合并为单次扫描，而 Pandas 需要多次遍历 DataFrame。

5.4 聚合操作性能

按天事件计数（daily_event_counts）

子集规模	Pandas (s)	Polars (s)	备注
10%	0.334	0.387	Polars 略慢（冷启动开销）
50%	2.073	2.335	接近持平
100%	⚠️ 跳过	1.850	Polars 完成

会话长度统计（session_length_summary）

子集规模	Pandas (s)	Polars (s)	Polars 加速比
10%	1.396	0.422	3.3×
50%	8.221	4.009	2.1×
100%	⚠️ 跳过	6.094	—

规律性发现：对于小规模聚合任务（如按天分组），Polars 的启动开销与 Pandas 相当，甚至略慢。但随着数据量增加和操作复杂度提升，Polars 的性能优势愈发显著。高基数列（如 user_session）的分组聚合场景是 Polars 优势最明显的场景之一。

5.5 基准测试可视化

 **图表提示：** 以下图表由 `data_preprocessing_benchmark.ipynb` 自动生成并保存至 `artifacts/figures/`：

- `artifacts/figures/preprocessing_benchmark_comparison.png` — 数据加载与预处理流水线的 Pandas vs. Polars 耗时与内存对比
- `artifacts/figures/aggregation_benchmark_comparison.png` — 按天聚合与会话统计两项聚合操作的性能对比
- `artifacts/figures/runtime_speedup_ratio.png` — Polars 相对 Pandas 的运行时加速比可视化
- `artifacts/figures/cleaning_scale_comparison.png` — 不同数据规模下的清洗效果对比

6. Task 3：基线探索性数据分析（EDA）

对应文件： `Baseline_EDA.ipynb`

本模块使用 100% 清洗后数据集，通过 Polars 完成所有计算，仅在绘图前将结果转换为 Pandas DataFrame，以实现计算效率与可视化便利性的平衡。

6.1 事件类型分布（Event Type Distribution）

数据集仅包含两类事件：**cart**（加购）和 **purchase**（购买），不包含浏览（view）事件。

 **图表提示：** 请插入 `Baseline_EDA.ipynb` Cell 13 的输出图表（Event Type Distribution 柱状图）。

从分布可以看出：

- **cart** 事件数量远多于 **purchase** 事件，反映用户存在大量「加购但未购买」的行为，即购物车弃置（Cart Abandonment）现象。
- 两类事件的比例关系为后续 Task 4 的购买转化率分析提供了宏观背景。

6.2 会话长度分布（Session Length Distribution）

 **图表提示：** 请插入 `Baseline_EDA.ipynb` Cell 14 的输出图表（Session Length Distribution 对数直方图）。

会话长度分布呈典型的长尾分布（Long-tail Distribution）：

- 大多数会话仅包含少量交互（1~5 次），用户平均会话较短。
- 少数高活跃会话包含数十至数百次交互，代表高参与度用户或机器爬虫行为。
- 纵轴采用对数坐标以清晰展示尾部分布特征。

6.3 每日事件趋势（Daily Event Trend）

 **图表提示：** 请插入 `Baseline_EDA.ipynb` Cell 14（Daily Trend）的输出折线图。

按日聚合的事件数量趋势揭示：

- 数据覆盖 2019 年 10 月至 2020 年 2 月，时序连续、无明显断层。
- 可观察到与电商促销节点（如 11 月双十一、黑色星期五）对应的活动峰值。
- 春节前后（2020 年 1 月末至 2 月初）存在一定程度的波动，可能反映季节性购物行为。

6.4 用户活跃度分布（User Activity Distribution）

 **图表提示：** 请插入 `Baseline_EDA.ipynb` Cell 15 的输出图表（对数直方图）。

用户交互次数同样呈长尾分布：

- 绝大多数用户的交互次数集中在个位数，属于低频访客。
- 少数「超级用户」贡献了极高频次的交互，是平台核心价值用户群体，值得重点维系。

6.5 热门商品与品类分析

 **图表提示：** 请插入 `Baseline_EDA.ipynb` Cell 16（Top 10 Products）和 Cell 17（Top Categories）的输出柱状图。

- **Top 10 热销商品：** 少数核心 SKU 承载了平台大部分交互流量，头部效应明显。
- **Top 品类（cat_1）：** 不同二级品类的互动量差异显著，头部品类集中了绝大部分用户注意力，为选品策略和流量分配提供参考。

6.6 小时活跃规律（Hourly Activity Pattern）

 **图表提示：** 请插入 `Baseline_EDA.ipynb` Cell 18 的输出折线图（Hour of Day vs. Events）。

用户行为呈现出清晰的日内周期规律：

- 深夜至凌晨（0~6 时）活跃度最低。
- 上午 10 时至晚间 22 时为活跃高峰区间，其中午后和晚间存在明显峰值。
- 该规律对平台的定时推送（Push Notification）、促销时间窗口选择和服务器资源调度具有直接指导意义。

7. Task 4：用户行为模式分析

对应文件： user_behavior_pattern_analysis.ipynb

本模块深入挖掘用户级别的行为模式，全部使用 100% 清洗数据，并对每个分析维度均执行 Pandas/Polars 性能对比。

7.1 用户购买转化率分析 & 新老用户路径差异

业务问题：用户从「加购」到「购买」的转化率是多少？新用户与老用户的行为路径有何差异？

实现逻辑：

- 按 user_id 分组，统计每个用户的 cart 事件数和 purchase 事件数，计算转化率 = 购买次数 / (加购次数 + ε)。
- 通过 event_timestamp 的最小值识别用户的首次交互时间，将首次交互即为当前事件的用户标记为「新用户」，其余为「老用户」。
- Polars 使用原生窗口函数 .over("user_id") 在 Rust 底层并行计算，避免 Python 层的对象序列化开销；同时开启 streaming=True 防止全量数据内存溢出。

性能对比：

框架	耗时 (s)	峰值内存 (GB)	内存增量 (GB)
Polars	3.38	2.87	0.001
Pandas	9.74	2.19	0.374
加速比	2.9×	—	—

 **图表提示：**请插入 user_behavior_pattern_analysis.ipynb Cell 5 的输出图表（Conversion Rate: New vs Returning 箱线图）。

业务洞察：新用户的转化率通常低于老用户，这与行业通识一致——老用户对平台信任度更高，决策链路更短。针对新用户的引导策略（如首单优惠、评价展示）具有较高的业务价值。

7.2 用户会话深度分析（Session Depth）

业务问题：不同会话中用户的交互深度（点击次数）和客单价（平均价格）如何分布？

实现逻辑：按 `user_session` 分组，计算每个会话的事件总数（`session_length`）和平均商品价格（`avg_session_price`）。`user_session` 是典型的高基数列（高达数百万个唯一值），对其进行分组聚合对 Pandas 的哈希表构建造成巨大压力。

性能对比：

框架	耗时 (s)	峰值内存 (GB)	内存增量 (GB)
Polars	0.86	2.23	0.549
Pandas	14.41	2.01	0.167
加速比	16.7×	—	—

 **图表提示：**请插入 `user_behavior_pattern_analysis.ipynb` Cell 5 的输出图表（Top 10 Longest Sessions 水平条形图）。

会话深度分析是本项目中 Polars 加速比最显著的场景之一（**16.7 倍**），充分证明了 Polars 在处理高基数列聚合时的架构优势。

7.3 热门品类与品牌偏好分析（Category & Brand Affinity）

业务问题：哪些顶级品类（`cat_0`）的购买量最高？各品类下排名前两位的品牌是哪些？

实现逻辑：过滤 `purchase` 事件，按（`cat_0`，`brand`）双列分组统计购买次数，再通过排序取每个品类的 Top-2 品牌。Polars 的查询优化器将过滤操作下推至文件扫描阶段，大幅减少进入内存的数据量。

性能对比：

框架	耗时 (s)	峰值内存 (GB)	内存增量 (GB)
Polars	0.14	1.81	0.149
Pandas	1.94	3.02	1.198
加速比	14.0×	—	—

 **图表提示：**请插入 `user_behavior_pattern_analysis.ipynb` Cell 6（Dashboard）的输出图表，尤其是 Category-Brand Affinity Heatmap 部分。

业务洞察：品类-品牌偏好热力图直接揭示了平台的核心品牌生态。强势品牌在特定品类中占据绝对份额，是平台招商与流量倾斜的优先考量对象。

7.4 Task 4 综合性能仪表盘

 **图表提示：** 请插入 `user_behavior_pattern_analysis.ipynb` 最后输出的 Dashboard 图表（多子图综合性能与业务洞察面板）。

分析任务	Pandas (s)	Polars (s)	加速比
用户转化 & 新老用户	9.74	3.38	2.9×
会话深度分析	14.41	0.86	16.7×
品类-品牌偏好	1.94	0.14	14.0×

8. Task 5：推荐导向分析

对应文件： `Recommendation-Oriented Analysis.ipynb`

8.1 分析思路与方法选择

根据 Proposal 的明确要求，本模块**严格限定**在关联规则挖掘（Association Rule Mining）范围内，**禁止**使用深度学习、协同过滤神经网络等复杂机器学习模型。

分析路径： 将电商购买行为建模为「购物篮问题（Market Basket Analysis）」：

- 以 `user_session` 为事务单元（Transaction）
- 以商品/品类/品牌为项目（Item）
- 通过统计同一会话中不同项目的共现频率，提取关联规则

三大核心指标：

指标	公式	含义
支持度（Support）	$P(A \cap B) = \text{共现会话数} / \text{总会话数}$	规则的覆盖面，越高代表规则适用范围越广
置信度（Confidence）	$P(B \mid A) = P(A \cap B) / P(A)$	规则的准确率，买了 A 有多大概率也买 B
提升度（Lift）	$Confidence(A \rightarrow B) / Support(B)$	规则的有效性，>1 正相关，=1 随机，<1 负相关

分析层次：本模块按颗粒度从粗到细分三层实施：

层次	分析粒度	候选项数量	适用业务场景
品类层（宏观）	cat_0 顶级品类	510 个， $C(10,2)=45$ 对	首页品类推荐、跨品类导流
品牌层（中观）	Top-30 品牌	$C(30,2)=435$ 对	品牌联合促销、捆绑折扣
商品层（微观）	Top-100 热销 SKU	$C(100,2)=4,950$ 对	商品详情页「猜你喜欢」

候选集预筛选策略是应对「组合爆炸」问题的关键：全量商品可能有数万个 SKU，直接挖掘将产生数亿个候选对，计算不可行且大多数规则统计意义不足。

8.2 品类关联规则挖掘

阈值设置： min_support=0.0005 , min_confidence=0.02

注：初始设置 support=0.005 导致结果为空，原因是 cat_0 为顶级品类，用户在单次会话中跨大品类购买的行为极少（绝大多数会话仅涉及单一大类），降低阈值后方能捕获有统计意义的规则。

性能对比：

框架	耗时 (s)	内存增量 (GB)
Polars	—	—
Pandas	—	—

 图表提示：请插入 Recommendation-Oriented Analysis.ipynb Cell 6 输出图表中的：

- 图1：Category Lift Heatmap（品类 Lift 热力图）
- 图2：Category Rules Confidence vs. Lift（散点气泡图）
- 图4：Category Rules Support Top 10（柱状图）

业务洞察：

- Lift 热力图中颜色较深的方格代表两个品类之间存在较强的正向关联，可直接用于首页品类推荐位的规则配置。
- 高 Lift 但低 Support 的规则适合作为「精准小众推荐」；高 Support 但中等 Lift 的规则适合作为「广覆盖通用推荐」。

8.3 品牌关联规则挖掘

阈值设置： min_support=0.002 , min_confidence=0.05 , Top-30 品牌白名单

从性能图表（图6）可见，品牌规则挖掘是三类任务中 Polars 加速比最高的一项（约 26x），这归因于 Polars 两阶段查询设计：第一阶段仅扫描 brand 列统计频次，第二阶段利用白名单过滤后再聚合，两次查询均由 Polars 优化器自动优化 I/O 路径。

 **图表提示：** 请插入 Recommendation-Oriented Analysis.ipynb Cell 6 输出图表中的：

- 图3： Top Brand Association Rules （水平条形图，含 Lift=1 随机基线标注）

代表性规则示例（来自图表实际输出）：

规则（Antecedent → Consequent）	Lift
apple → samsung	~35
samsung → apple	~35
huawei → samsung	~30
samsung → huawei	~30
samsung → xiaomi	~28

业务洞察： 苹果与三星、华为与三星之间呈现出显著的正向关联（Lift 远大于 1），说明购买高端手机品牌的用户高度倾向于同时购买另一个高端品牌的产品（如配件、周边或第二台设备）。这为品牌联合促销活动提供了强有力的数据支撑。

8.4 商品级别关联分析（Top-100 SKU）

阈值设置： min_support=0.0001 , min_confidence=0.02 , Top-100 热销商品

支持度分母统一使用全量购买会话数（而非仅含 Top 商品的会话数），确保指标口径正确，避免人为虚高支持度。

 **图表提示：** 请插入 Recommendation-Oriented Analysis.ipynb Cell 6 输出图表中的：

- 图5： Product Rules Distribution （Support vs. Confidence 散点图，颜色=Lift）

业务洞察： 从散点图可以看出，高 Confidence 规则（纵轴上部）往往对应中等 Support 水平，说明这些规则的推荐精准度高但覆盖面有限，适合部署在高流量商品的详情页侧边栏，作为精准「连带推荐」。

8.5 性能综合对比

 **图表提示：** 请插入 Recommendation-Oriented Analysis.ipynb Cell 6 输出图表中的：

- 图6：Performance: Pandas vs. Polars（三类任务性能对比对数坐标柱状图，含加速比标注）
- 整体 Dashboard：artifacts/figures/recommendation_analysis.png

从 Cell 6 图表的实际数值标注可读取：

分析任务	Polars 加速比（相对 Pandas）
品类关联规则	5.9x
品牌关联规则	26.3x
商品关联规则	14.5x

9. 综合性能对比与讨论

9.1 跨任务加速比汇总

下表汇总了本项目所有主要分析任务中 Polars 相对 Pandas 的加速比：

任务模块	具体操作	Polars 加速比
Task 1&2	数据加载（10% 子集）	3.0x
Task 1&2	预处理流水线（10% 子集）	31.0x
Task 1&2	预处理流水线（50% 子集）	16.9x
Task 1&2	会话长度统计（10%）	3.3x
Task 1&2	会话长度统计（50%）	2.1x
Task 4	用户转化率 & 新老用户	2.9x
Task 4	会话深度分析（高基数聚合）	16.7x
Task 4	品类-品牌偏好分析	14.0x
Task 5	品类关联规则挖掘	5.9x

任务模块	具体操作	Polars 加速比
Task 5	品牌关联规则挖掘	26.3×
Task 5	商品关联规则挖掘	14.5×

9.2 关键规律总结

1. 操作类型决定性能差距幅度

- 大规模分组聚合（高基数列）是 Polars 优势最显著的场景，加速比通常超过 10×
- 简单单列聚合（如按天计数）两者差距较小，Polars 甚至在小数据量时因初始化开销而略慢。
- 预处理流水线（多列类型转换）中 Polars 的惰性求值优化器优势最突出，可将多步操作合并为单次扫描。

2. 内存使用模式截然不同

- Pandas 将整个 DataFrame 完整载入内存，内存增量与数据规模正相关。
- Polars 的流式引擎（ streaming=True ）实现真正的「按需计算」，内存增量在 100% 全量数据下依然维持在极低水平（部分任务内存增量不足 0.001 GB）。
- 在本项目运行环境（约 16 GB 物理内存）下，Pandas 处理 50% 子集（约 5.7M 行）时已开始出现性能抖动，100% 全量任务均触发内存熔断保护而被跳过；Polars 在所有规模下均顺利完成。

3. 可扩展性（Scalability）优势

Polars 的处理时间随数据量的增长呈接近线性的趋势，而 Pandas 的增长斜率更陡，在 50% → 100% 区间会出现明显的超线性增长。对于数据规模持续增长的电商生产环境，Polars 在可扩展性上具有压倒性优势。

4. 可用性对比

维度	Pandas	Polars
学习曲线	较低，生态成熟	相对陡峭，API 不同于 Pandas
与可视化库集成	直接兼容 Matplotlib/Seaborn	需 .to_pandas() 转换
调试友好性	高（即时模式）	略低（Lazy 模式的错误较隐晦）
大数据处理能力	受限于内存	流式处理突破内存瓶颈

10. 结论

本项目以 *RecSys 2020 Preprocessed eCommerce Behavior Dataset* (11.5M 行) 为研究对象，系统性地完成了从数据预处理、基线 EDA、用户行为模式分析到推荐导向分析的完整电商数据分析管道，并在每个环节量化对比了 Pandas 与 Polars 的性能表现。

主要发现如下：

1. **Polars 在大多数场景下显著优于 Pandas**，综合加速比介于 $3\times\sim 31\times$ 之间，在高基数列聚合和多步预处理流水线场景尤为突出。
2. **Polars 的流式处理引擎解决了 Pandas 的内存瓶颈问题**，使得在普通笔记本电脑 (16 GB 内存) 上处理千万级全量数据成为可能，而 Pandas 在相同环境下因内存限制无法完成全量任务。
3. **业务洞察层面**，通过五个任务模块的分析，提取了以下关键发现：
 - 用户行为呈现明显的日内周期规律，晚间为活跃高峰，可指导推送时机选择。
 - 购物车弃置率高，新用户转化率显著低于老用户，需针对性的引导策略。
 - 品牌关联分析揭示 apple-samsung、huawei-samsung 等高强度共现组合，直接支持联合营销决策。
 - 商品级关联规则 (Top-100 SKU) 可直接落地为「购买此商品的用户还购买了」推荐模块。
4. **工具选择建议**：对于数据规模在百万行以下、团队已有 Pandas 经验的场景，Pandas 仍是合理选择；一旦数据规模超过数百万行、或涉及高基数聚合操作，迁移至 Polars 可带来实质性的效率提升，且无需引入分布式计算平台。

本项目所构建的分析框架具有良好的可复现性和可扩展性，代码结构清晰、注释完备，可作为后续大规模电商数据分析的参考基准。

11. 参考文献

Schettler, D. (2021, January 1). *Recommender System - e-commerce dataset - 2020*. Kaggle.
<https://www.kaggle.com/datasets/dschettler8845/recsys-2020-ecommerce-dataset/data>

Apache Parquet. (n.d.). *Apache Parquet documentation*. Apache Software Foundation.
<https://parquet.apache.org/docs/>

Jannach, D., Quadrana, M., & Cremonesi, P. (2022). Session-based recommender systems. In F. Ricci, L. Rokach, B. Shapira, & P. B. Kantor (Eds.), *Recommender Systems Handbook* (3rd ed., pp. 301–335). Springer.

Pandas development team. (n.d.). *About pandas*. <https://pandas.pydata.org/about/>

Polars. (n.d.). *Lazy API*. <https://docs.pola.rs/user-guide/concepts/lazy-api/>

本报告为草稿版本 (Chinese Draft)，图表引用处已标注插入提示，最终版本请替换为对应 Notebook 的实际输出图表。